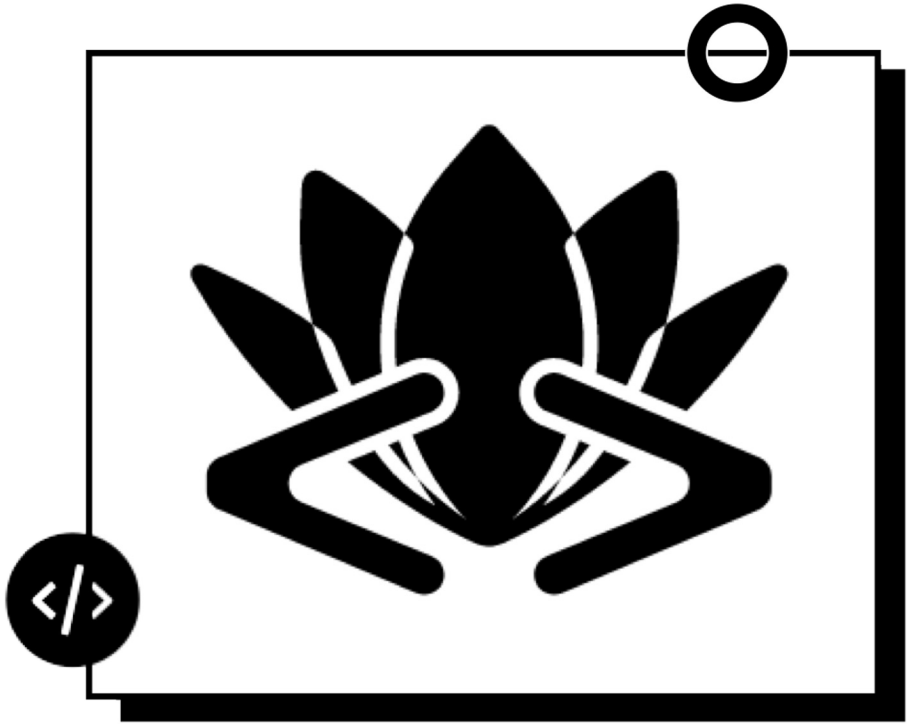


AS RAPARIGAS DO CÓDIGO

Workshops de Python para Data Science (1ª ed)

2 Abril – 14 Maio

Agenda

Sessão de Abertura, Comunidade & Mentores

Introdução ao Curso

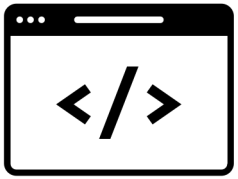
Introdução à Ciência de Dados

- Profissões, Skill Stack, Carreiras e Empresas
- Data Science, Aplicações e Tarefas
- Machine Learning: Conceitos e Notação
- Exemplos

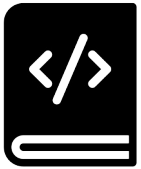
Sessão de Abertura

Visão

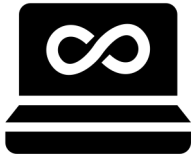
Women Coding Programs



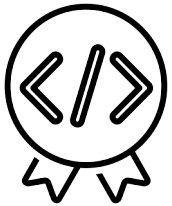
Code Schools



Digital Education



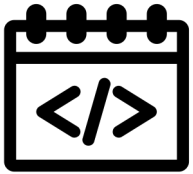
Reskilling Upskilling



Portuguese Tech Communities



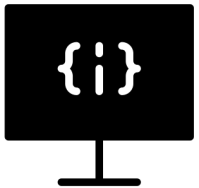
Inclusion Initiatives



Government Initiatives



Corporate Initiatives

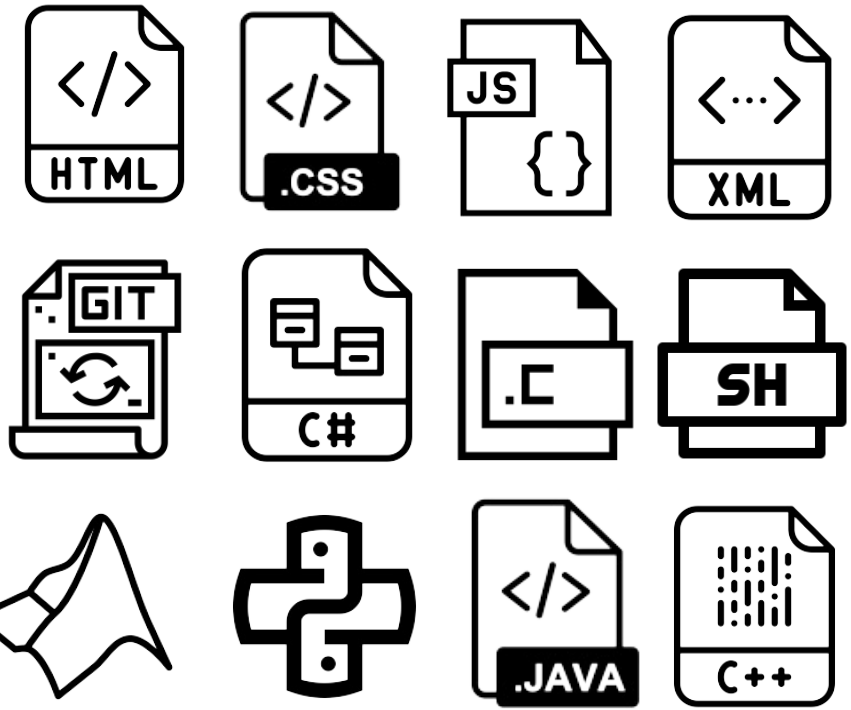


Educação

As Raparigas do <Código/>

Comunidade

Skill Stack



- Bases de Dados
- Cibersegurança
- Ciência de Dados
- Mobile (iOS, Android)

Comunidade

Código de Conduta

A nossa comunidade é um espaço **inclusivo** e **seguro**;

Podes interagir com toda a gente, desde que seja sempre com **respeito** e **cuidado**. Estamos todos a dar o nosso melhor e a aprender nesse processo;

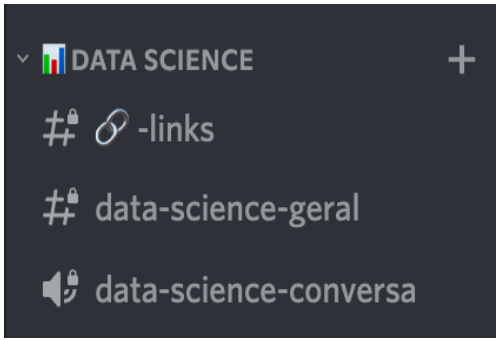
Comentários discriminatórios ou abusivos em relação às alunas ou mentores **não serão tolerados**.

Discord

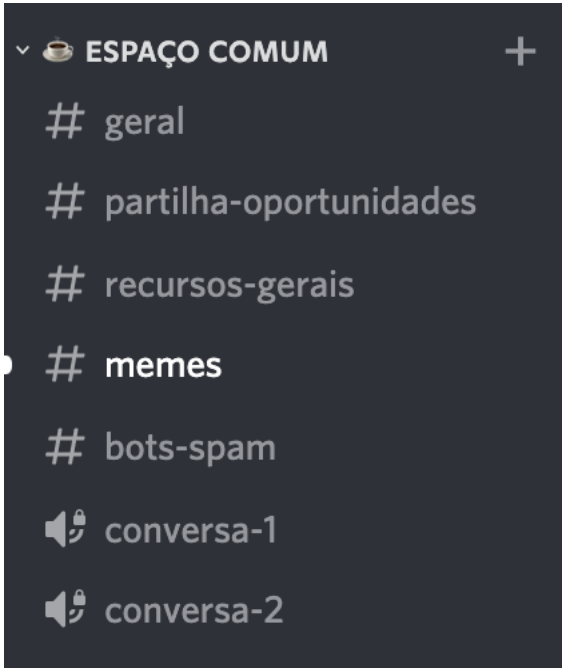
Espaço aberto à comunidade! ☺

Canais específicos para cada atividade;

Canais deste curso:







GitHub

Também temos a nossa organização no GitHub!

https://github.com/As-Raparigas-do-Codigo

Repositório **python-data-science-ed-1**

- Calendário e Planeamento
- Bibliografia
- Material das aulas
- (...)



Mentores

Introdução ao Curso

Funcionamento

Workshops de Python para Data Science (1ª edição)

7 semanas, 2 de Abril a 14 de Maio

Sábados, 10h-12h (2 horas)

Workshops online (via zoom)

Sessões teórico-práticas (live coding)

Jupyter Notebooks

Pré-Requisitos: Domínio Básico do Python (incluindo ciclos “for” ☺)

Calendário

Data	Tópicos
2 de Abril	Introdução à Ciência de Dados. Sessão de Abertura Introdução ao Jupyter Notebook
9 de Abril	Análise Exploratória de Dados: Parte 1. Leitura de dados a partir de ficheiros CSV. Biblioteca Pandas.
16 de Abril	Análise Exploratória de Dados: Parte 2. Bibliotecas NumPy e SciPy. Visualização de dados. Biblioteca Matplotlib.

Calendário

23 de Abril	Pré-Processamentos de Dados. Discretização e normalização de variáveis. Dados em falta e dados desequilibrados.
30 de Abril	Construção e Avaliação de Modelo: parte 1 Aprendizagem automática. Modelos supervisionados. Regressão linear. Medidas de erro: MAE, MSE e RMSE.
7 de Maio	Construção e Avaliação de Modelo: parte 2 Classificação. Regressão Logística. Métricas de classificação: matriz de confusão.
14 de Maio	Sessão de Encerramento. Carreiras e Oportunidades em Ciência de Dados. Projetos para Iniciantes.

Planeamento das aulas

O material das aulas será partilhado até 1 dia antes da aula (sexta à noite): ficheiros, slides, instruções;

Exercícios e tutoriais são colocados no final dos Jupyter Notebooks das aulas ou na página do GitHub do curso;

Planeamento das aulas

Se não puderem vir a uma aula, **avisem o vosso mentor**, de forma a que a falta seja justificada;

Os certificados de término do curso serão dados para **presenças >= a 5 sessões**;

As alunas mais responsáveis e empenhadas são recompensadas com **acesso prioritário** a novos workshops e oportunidades de estágio e formação.

Bibliografia

Data Science from Scratch: First Principles with Python, 2nd Edition, O'Reilly, 2019

Python Data Science Handbook: Essential Tools for Working with Data, O'Reilly, 2016

Data Science, The MIT Press Essential Knowledge series, 2018

Material das aulas em PT ☺ (Jupyter Notebooks e notas)

Mentorias

Todas as alunas terão um/a mentor/a atribuído aleatoriamente;

Cada grupo de alunas tem acesso ao canal desse mentor (e.g., #mentorias-rita) onde pode procurar ajuda dos mentores e das colegas;

Ferramentas

Google Colab:

https://colab.research.google.com

Só precisam de uma conta de Gmail ☺

A cada aula, façam uma cópia do Jupyter Notebook para o vosso Drive, e podem editar e guardar o ficheiro;

Introdução à Ciência de Dados

Profissões em Data Science

Data Scientist: Participação em todas as fases do projeto

Machine Learning Engineer: Desenvolvimento de modelos e deployment para produção

Machine Learning Scientist: R&D, "académico na indústria" (Research Scientist, Research Engineer)

Statistician: Maior foco na análise estatística

Data Analyst: Análise e *Reporting*

Data Storyteller: Encontra uma narrativa para descrever os dados (mais do que visualização)

Business Intelligence Developer: *Dashboarding* e *Reporting*

Business Analyst: Maior foco nos sistemas e processos do negócio

Marketing Scientist: Foco no marketing e vendas

Profissões em Data Science

Data Modeler: Design das BDs

Data Administrator: Administração e manutenção das BDs

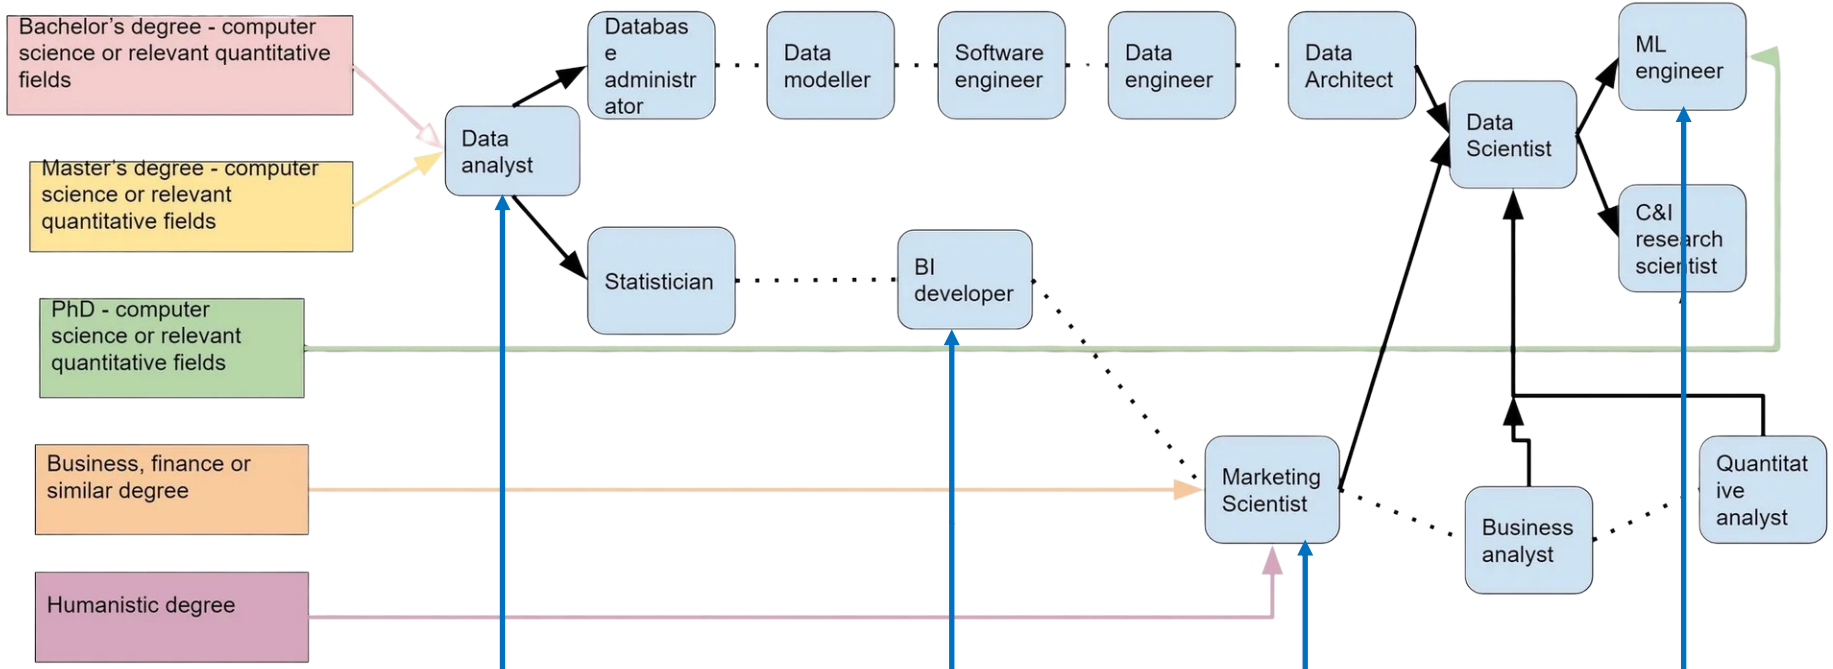
Data Engineer: Preparação da infraestrutura, automação, manipulação e processamento de dados, optimização (*data pipelines*)

Data Architect: Arquitectura e infraestrutura de armazenamento de dados (high level, orientado ao negócio)

Software Engineer: Desenvolvimento de software

Especialistas Técnicos: Deep Learning, Data Quality, NLP...

Career Path



https://www.kdnuggets.com/2021/10/guide-14-different-data-science-jobs.html

Skill Stack para Data Science



https://www.kdnuggets.com/2021/10/guide-14-different-data-science-jobs.html

Skill Stack para Data Science

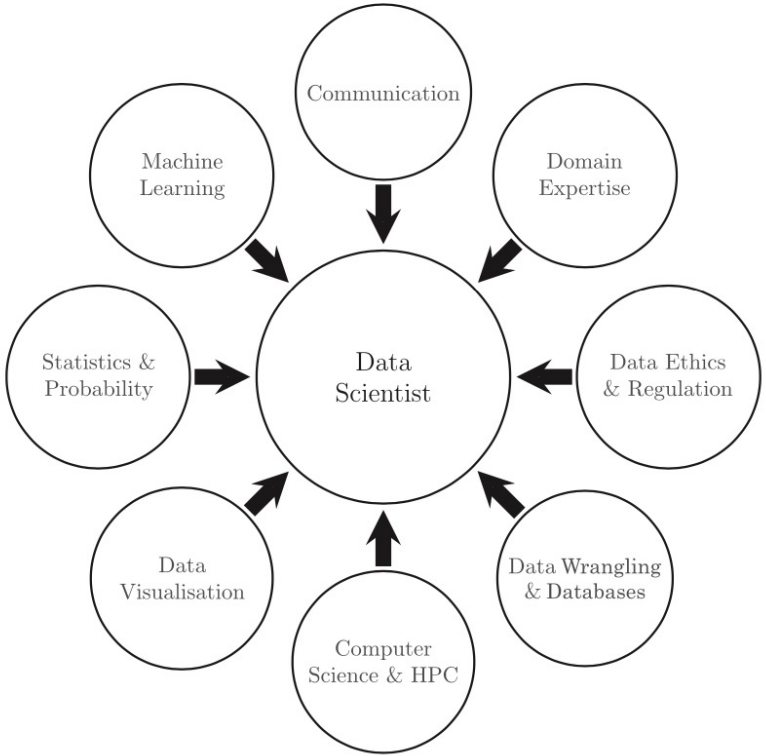


Figure 1 A skills-set desideratum for a data scientist.

Skill Stack para Data Science

Programação:

Python, R, MatLab

Plataformas e Ferramentas:

Data Science e Machine Learning: Jupyter Notebooks, MS Azure Learning Studio, IBM Watson Machine Learnign, KNIME, WEKA

Business Intelligence: Power BI, Tableau, Pentaho

Bases de Dados: PostgreSQL, MySQL, Oracle

Cloud Databases: Amazon Web Service, Microsoft Azure, Google Cloud

Skill Stack para Data Science (Python)

pandas

numpy

scipy

matplotlib

scikit-learn

plotly

seaborn

theano

keras

pytorch

tensorflow

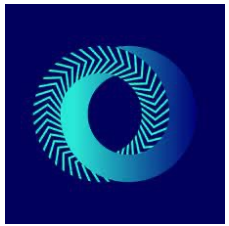
statsmodels

Empresas interessadas em Data Science

















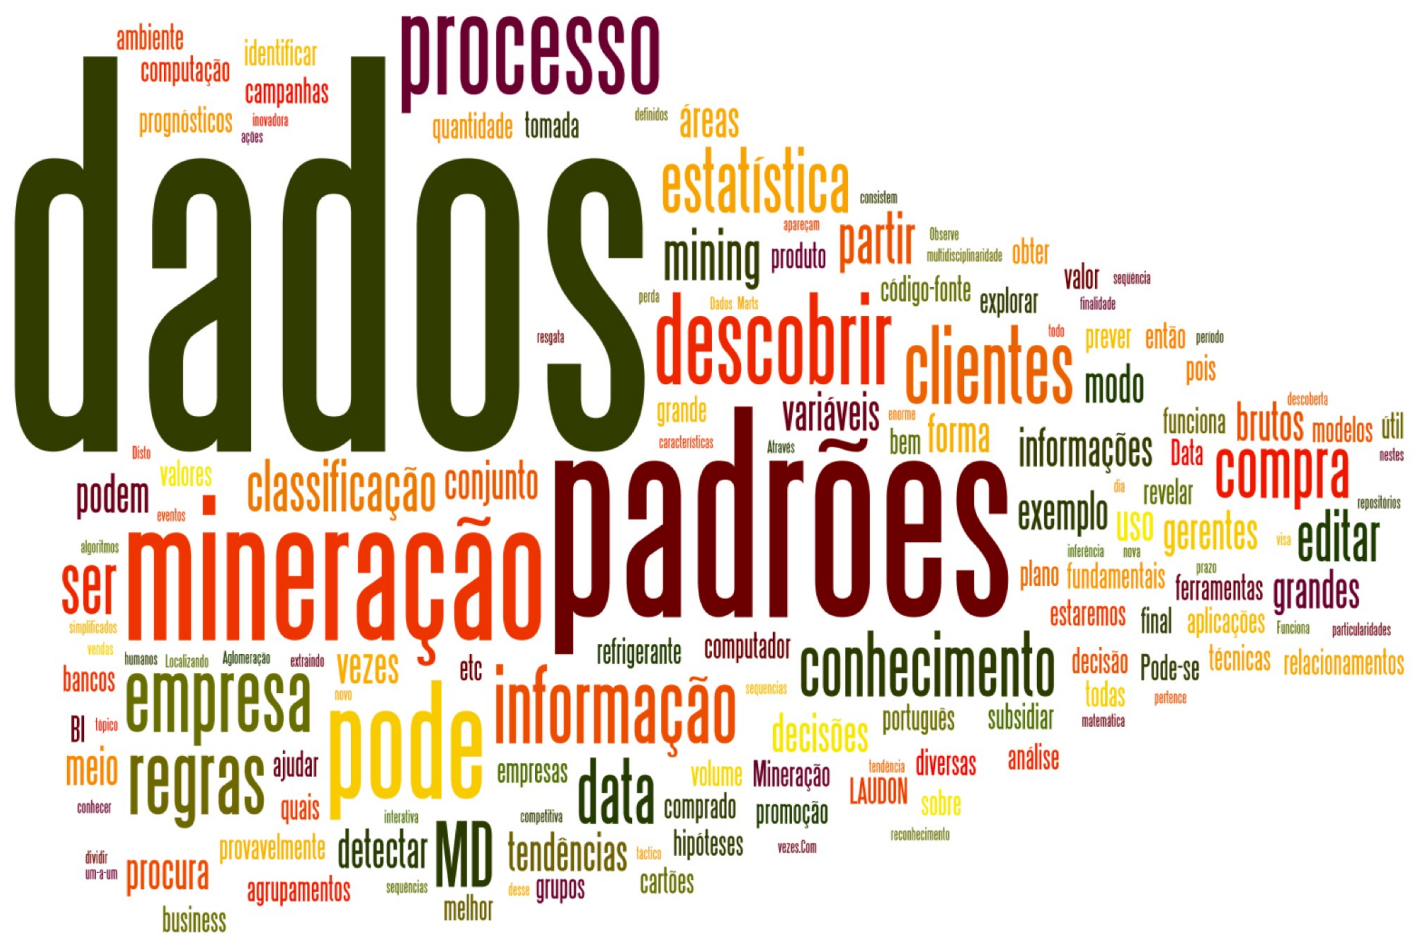








O que é "Data Science"


dados
processo
padrões
mineração
estatística
descobrir
clientes
conhecimento
informação
pode
empresa
regras
data
MD
ser
compra
editar
grandes
ferramentas
gerentes
exemplo
uso
informações
classificação
conjunto
valores
podem
variáveis
mining
partir
produto
código-fonte
explorar
modo
prever
então
pois
funciona
brutos
modelos
útil
Data
revelar
bem
forma
grande
ambiente
computação
identificar
campanhas
prognósticos
inovadora
ações
quantidade
tomada
definidos
áreas
consistem
apareçam
Observe
multidisciplinaridade
obter
valor
sequência
finalidade
perda
Dados
Marts
resgata
todo
período
descoberta
enorme
características
Através
Disto
dia
repositórios
nestes
visa
nova
inferência
plano
fundamentais
prazo
estaremos
final
aplicações
Funciona
particularidades
técnicas
relacionamentos
Pode-se
pertence
todas
matemática
decisão
decisões
português
subsidiar
análise
diversas
LAUDON
sobre
reconhecimento
Mineração
volume
comprado
promoção
vezes.Com
hipóteses
cartões
tendências
tactico
grupos
desse
detectar
competitiva
empresas
interativa
sequencias
melhor
agrupamentos
provavelmente
procura
dividir um-a-um
business
ajudar
quais
meio
conhecer
BI
tópico
bancos
humanos
Localizando
Aglomeração
extraindo
vezes
novo
etc
refrigerante
computador
sequencias
algoritmos
simplificados
vendas
eventos

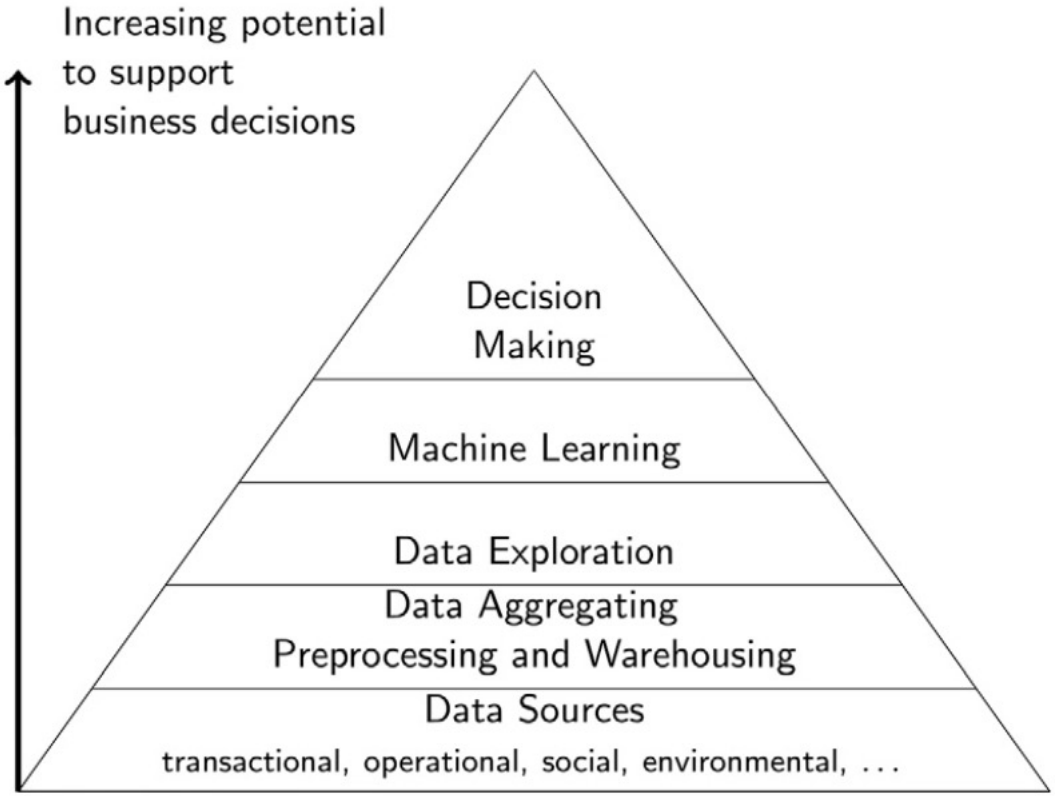
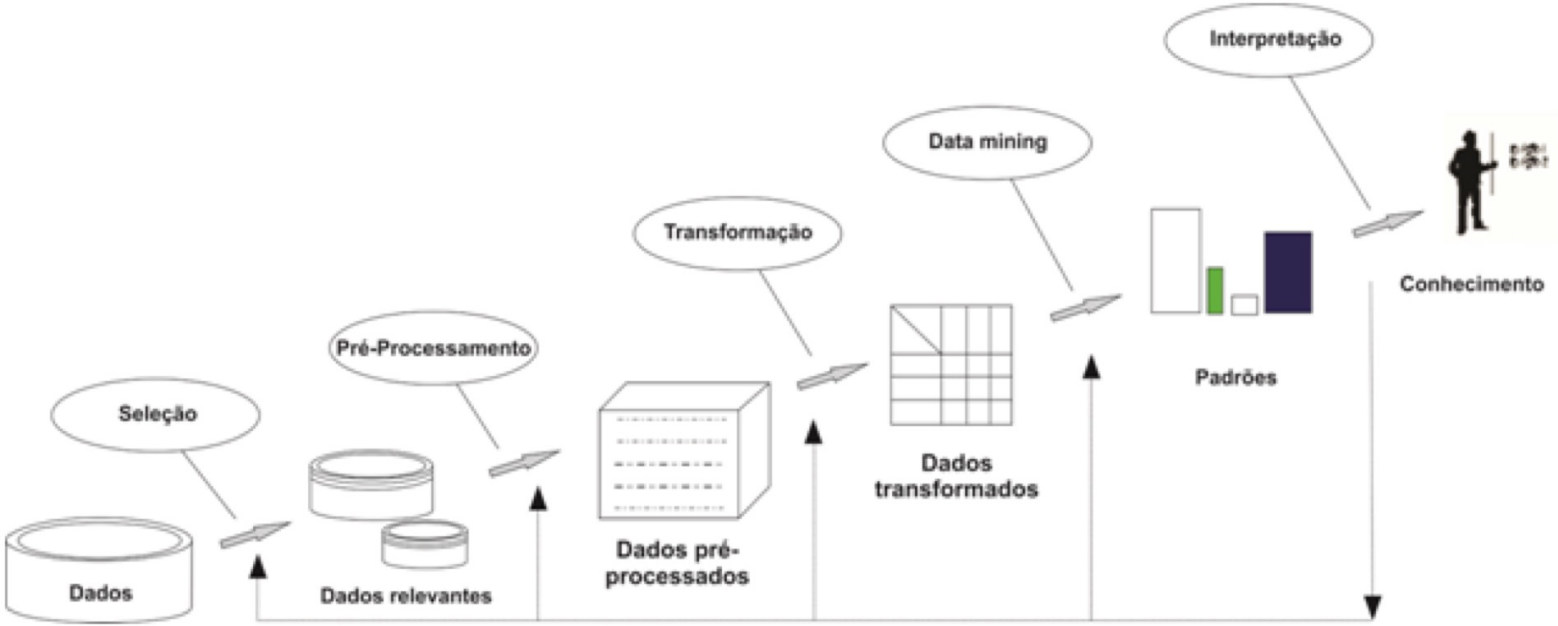


Figure 3 Data science pyramid (adapted from Han, Kamber, and Pei 2011).

Knowledge Discovery in Databases (KDD)





BDs operacionais

Data Warehouse



Selecção dos Dados

Nome	Idade	Rendimento	Linha de Crédito
Maria	20 — 30	baixo	mau
Pedro	40 — 50	médio	—
João	30 — 40	baixo	médio
Marcelo	30 — 40	alto	bom
Bruno	20 — 30	—	9999
Cecília	20 — 30	médio	médio
José	40 — 50	alto	bom
Antónia	40 — 50	alto	bom

Limpeza dos Dados

Nome	Idade	Rendimento	Linha de Crédito
Maria	20 — 30	baixo	mau
João	30 — 40	baixo	médio
Marcelo	30 — 40	alto	bom
Cecília	20 — 30	médio	médio
José	40 — 50	alto	bom
Antónia	40 — 50	alto	bom

Enriquecimento dos Dados

Nome	Idade	Rendimento	Linha de Crédito	Profissão
Maria	20 — 30	baixo	mau	Professora
João	30 — 40	baixo	médio	Advogado
Marcelo	30 — 40	alto	bom	Médico
Cecília	20 — 30	médio	médio	Engenheira
José	40 — 50	alto	bom	Dentista
Antónia	40 — 50	alto	bom	Cabeleireira

Criação do modelo

Modelo de Classificação

Se IDADE > "30 — 40"
ou RENDIMENTO = "alto"
então LINHA DE CRÉDITO = "bom"

Visualização



Classificação



Dados não-classificados

Nome	Idade	Rendimento	Linha de Crédito
Marcelino	20 — 30	baixo	?
Barata	40 — 50	médio	?

Linha de Crédito
mau
bom

Cross Industry Standard Process for Data Mining (CRISP- DM)

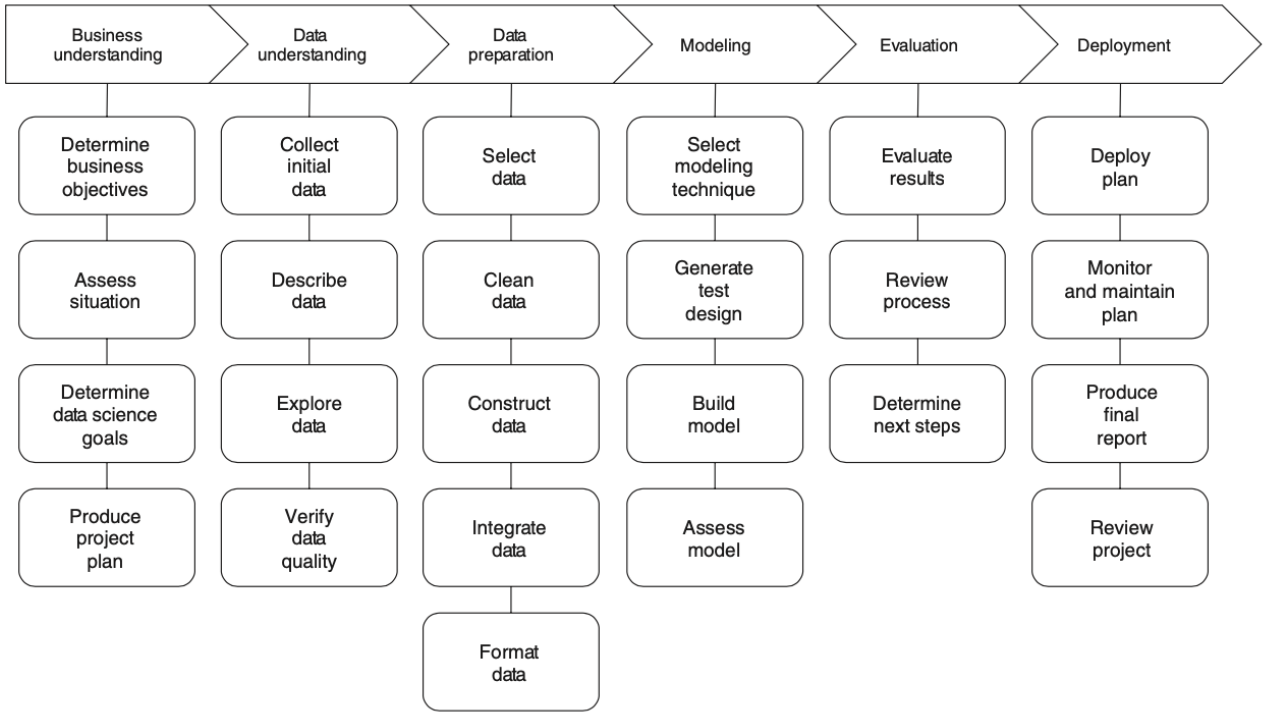
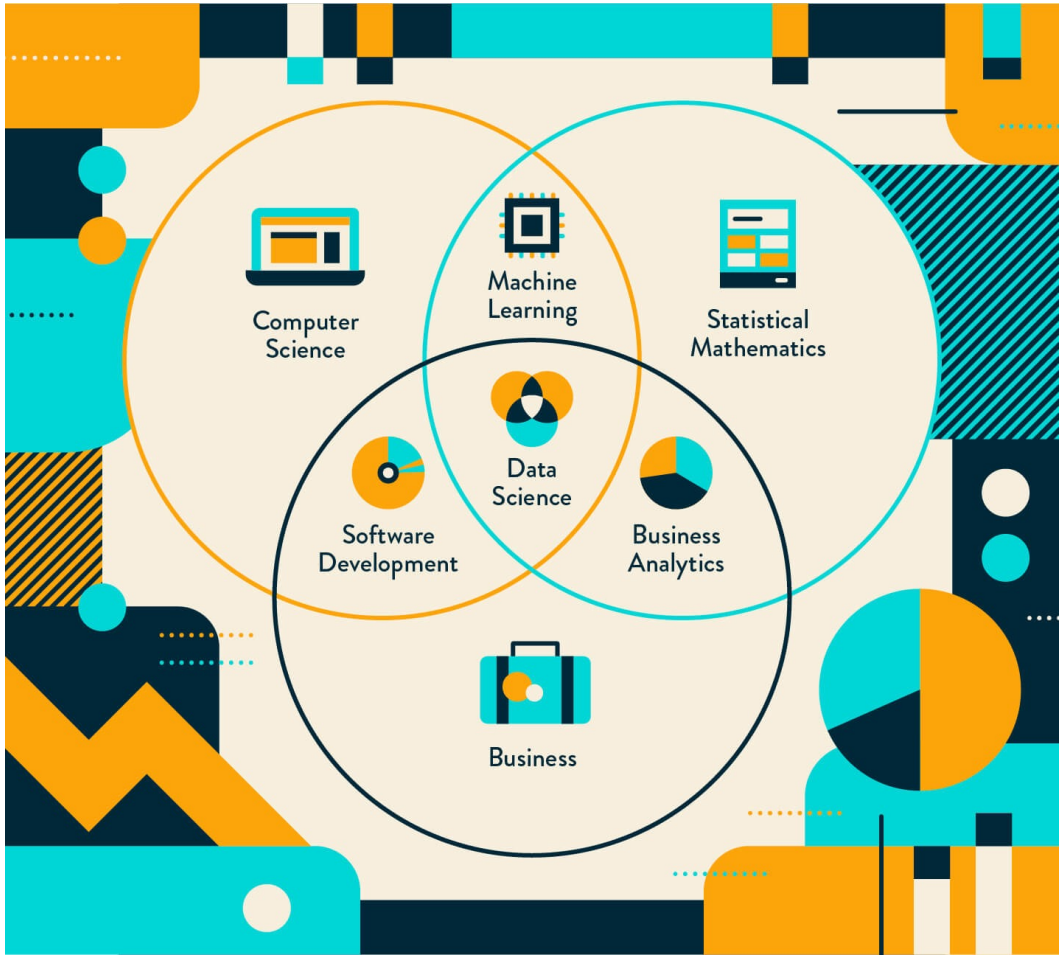


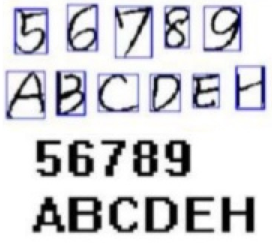
Figure 5 The CRISP-DM stages and tasks (based on figure 3 in Chapman, Clinton, Kerber, et al. 1999).


Computer Science
Machine Learning
Statistical Mathematics
Data Science
Software Development
Business Analytics
Business

Aplicações



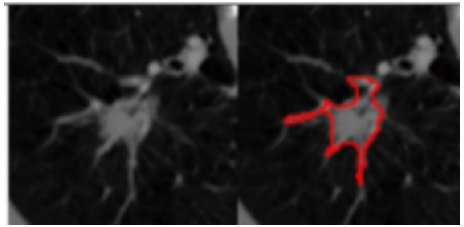




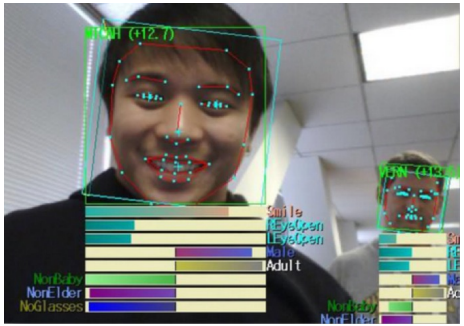


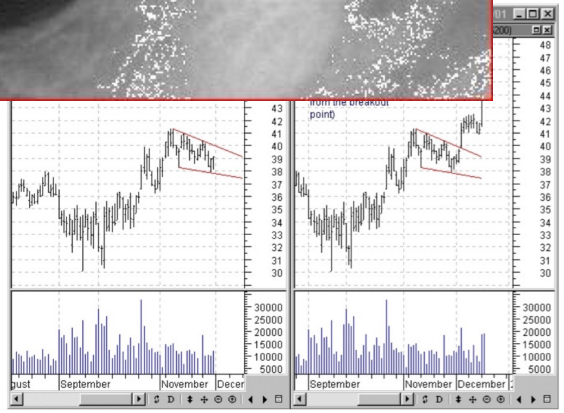


Malignant











AS RAPARIGAS DO CÓDIGO

Data Science Tasks

Tarefas/Problemas em Data Science

Previsão (**Classificação ou Regressão**)

Clustering (segmentação)

Regras de Associação

Classificação

Diagnóstico de um tumor

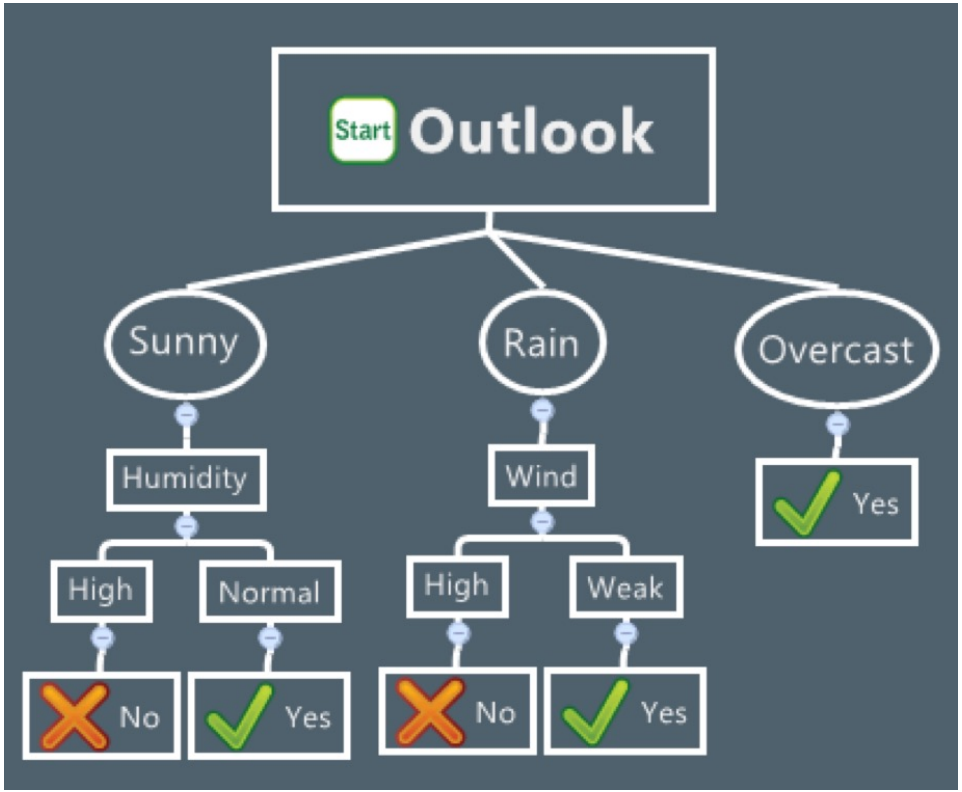
(benigno/maligno)

Análise de padrões cerebrais

(acordado/a dormir)

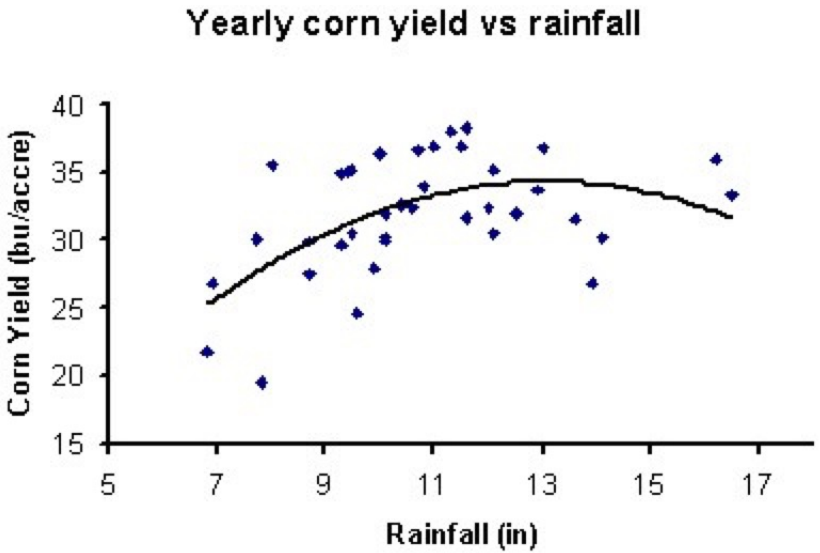
Seguro de vida (alto

risco/médio/baixo)



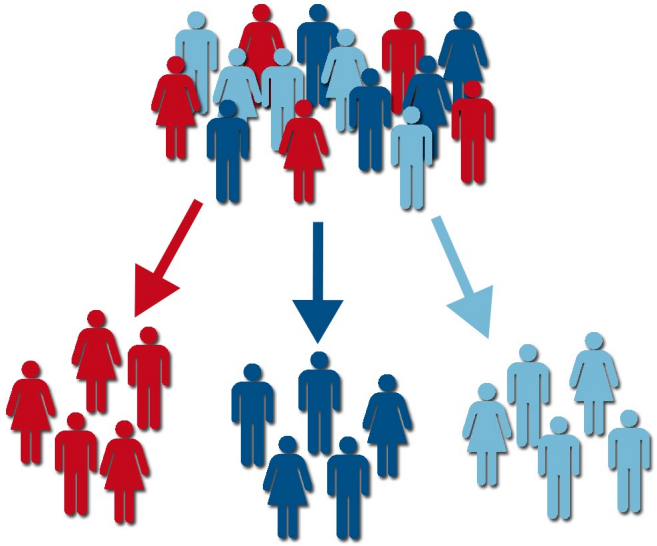
Regressão

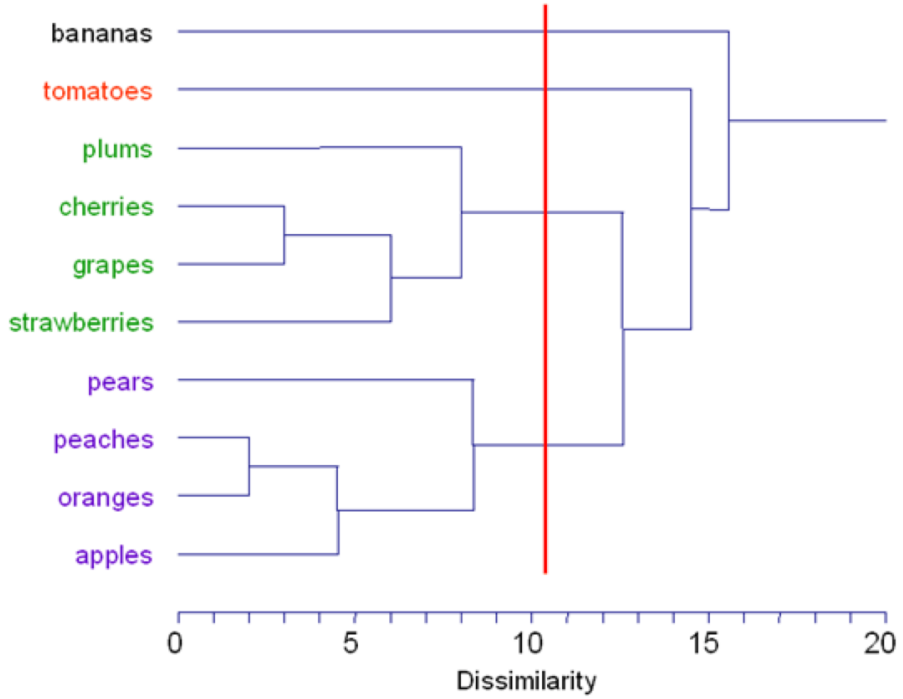
Estimação de relações entre variáveis: prever uma variável dependente usando diversos preditores (variáveis independentes)



Clustering (Agrupamentos)

Dados agrupados segundo características comuns (semelhanças)

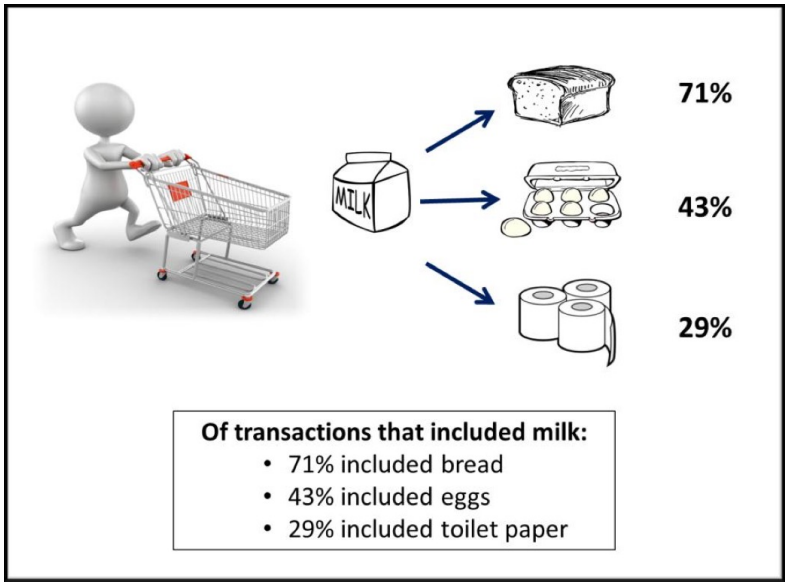




Regras de Associação

Market Basket Analysis: que produtos são comprados em conjunto?





Machine Learning (Aprendizagem Automática)

Conceitos e Notação

Dados ou *Dataset*, matriz de dados

Aprendizagem Supervisionada vs Não Supervisionada

Classe ou *Target*

Features ou Variáveis ou Características ou Atributos

Algoritmos ou modelos

Padrões ou Exemplos ou “Pontos” ou “*Samples*”, *Records*, Casos, Instâncias

Input e Output

Padrões, Classes e Características

Um **padrão** (*pattern*) é um objecto, um processo ou evento (na verdade, é uma *representação* desse objecto, processo ou evento, mas as definições são usadas sem distinção);

Uma **classe** (*class*) é um estado da "natureza", é uma *categoria* de objectos associada a um conceito ou protótipo;

Características (*features*) são medidas ou atributos derivadas dos padrões, que ajudam à sua caracterização;

Padrões, Classes e Características

O conjunto de **classes** Ω definidas para um problema, denomina-se espaço de interpretação *(interpretation space)*.

Num problema de classificação, assumimos ***c*** classes denotadas por:

$$\omega_i \in \Omega, (i = 1, ..., c)$$

Padrões, Classes e Características

Num projeto de data science, os **padrões** são tipicamente os casos ou amostras disponíveis, os objectos que pretendemos reconhecer (ou classificar).

Normalmente utilizamos a letra **n** para indicar o total de padrões disponíveis para o desenho do sistema (conjunto de treino).

Padrões, Classes e Características

Cada **padrão** é descrito por um conjunto de ***d* características**, de modo que pode ser representado por um vector dessas ***d*** caraterísticas *(feature vector):*

$$\mathbf{x} = [x_1, x_2, ..., x_d] \in X$$

X é o domínio ***d***-dimensional de todos os padrões (*feature space ou espaço de representação)*

Exemplos

Iris Dataset

Iris dataset:

https://archive.ics.uci.edu/ml/datasets/Iris

https://www.kaggle.com/datasets/uciml/iris



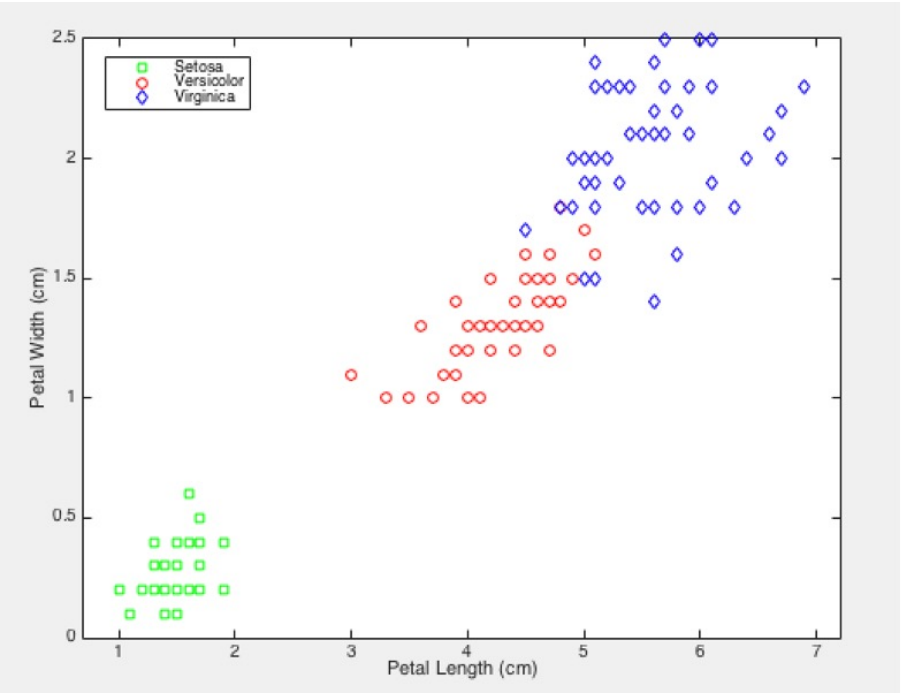
Iris Dataset

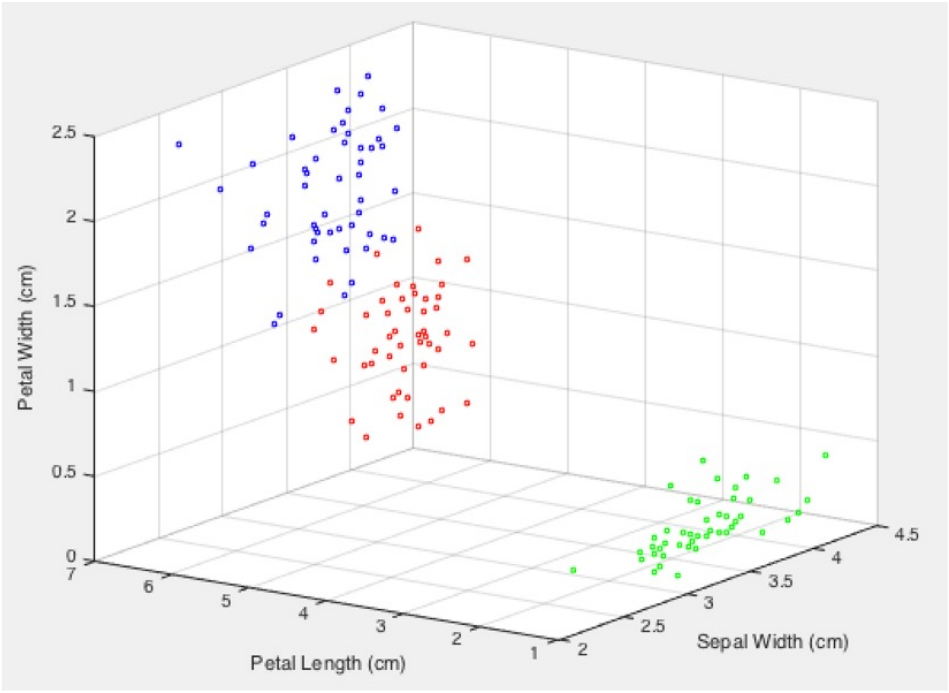
Detail | Compact | Column

6 of 6 columns

Id	SepalLeng...	SepalWidt...	PetalLengt...	PetalWidth...	Species
1	5.1	3.5	1.4	0.2	Iris-setosa
2	4.9	3.0	1.4	0.2	Iris-setosa
3	4.7	3.2	1.3	0.2	Iris-setosa
4	4.6	3.1	1.5	0.2	Iris-setosa
5	5.0	3.6	1.4	0.2	Iris-setosa
6	5.4	3.9	1.7	0.4	Iris-setosa
7	4.6	3.4	1.4	0.3	Iris-setosa
8	5.0	3.4	1.5	0.2	Iris-setosa
9	4.4	2.9	1.4	0.2	Iris-setosa

Iris Dataset





Iris Dataset

Contém **3 classes** com **50 padrões cada**, onde cada classe se refere a uma das espécies da planta íris (flor-de-lis)

Características: sepal length, sepal width, petal length, petal width (cm)

Classes: íris versicolor, íris virginica e íris setosa

ECG

Diagnóstico de condições cardíacas através da interpretação de ECGs:

Padrões, classes, características?

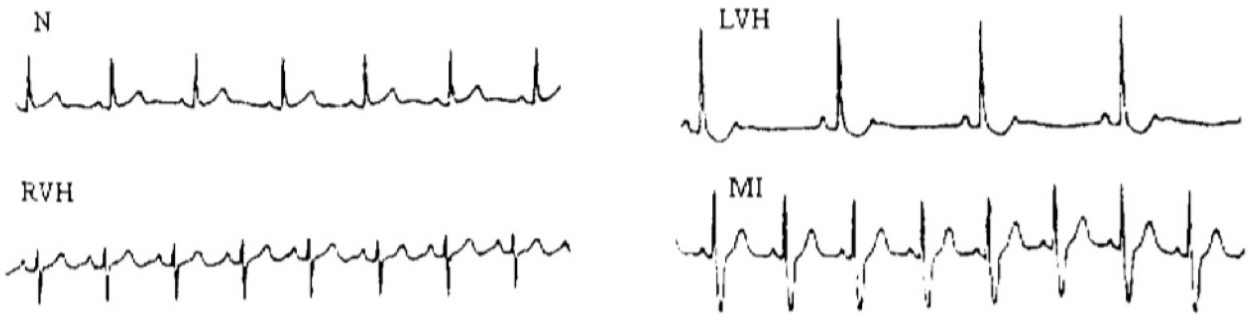


Figure 1.8. ECGs of 4 diagnostic classes: (N) Normal; (LVH) Left ventricular hypertrophy; (RVH) Right ventricular hypertrophy; (MI) Myocardial infarction.

ECG

Cada sinal corresponde a condição fisiológica distinta: normal, LVH, RVH ou MI (**uma classe!**)

Para diagnosticar um doente, o cardiologista interpreta a morfologia do sinal e procura fazer a correspondência com a condição fisiológica do coração.

Existem ***c = 4*** classes, descritas por:

$$\omega_i \in \Omega, i = \{\mathrm{N}, \mathrm{LVH}, \mathrm{RVH}, \mathrm{MI}\}$$

ECG

Os ECGs que o data scientist vai procurar reconhecer são os **padrões.**

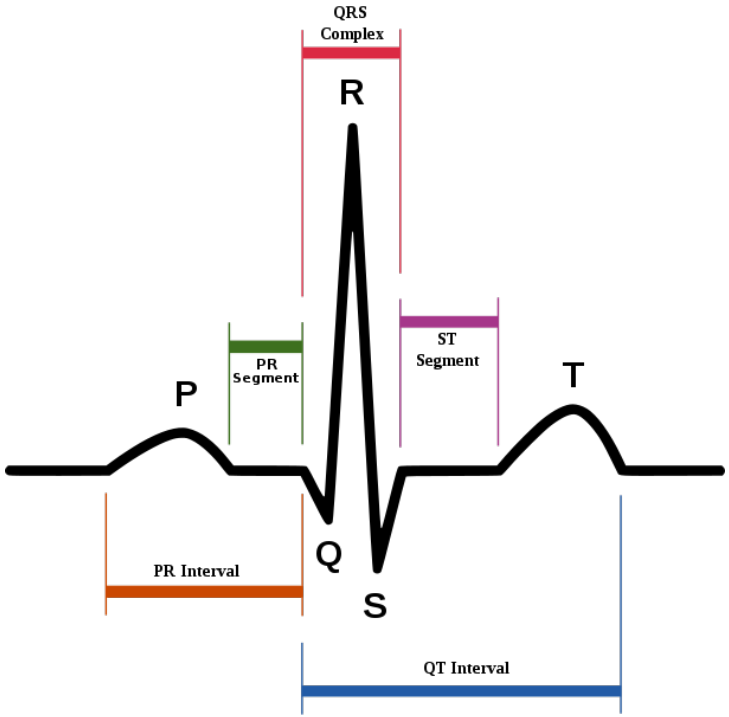
Imaginando que se realizam exames para 20 doentes, temos ***n = 20 ECGs***, portanto ***n = 20 padrões***.



ECG

- Cada ECG tem de ser descrito por atributos que o caracterizem (**características**):
  - Amplitude dos picos R;
  - Razão entre as amplitudes das ondas R e Q *(Q/R ratio)*

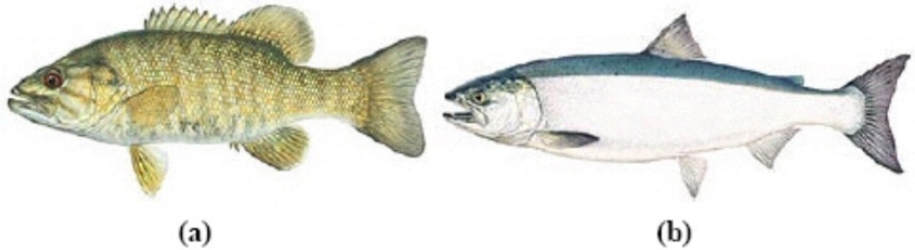
$$ECG_1 = [Q/R_1, Amp_1];$$
$$ECG_2 = [Q/R_2, Amp_2];$$
$$ECG_3 = [Q/R_3, Amp_3];$$



Perca ou Salmão?

O nosso trabalho como *data scientists* é desenvolver um sistema que distinga automaticamente uma perca de um salmão, através de detecção ótica (fotografias).





Perca ou Salmão?

Aquisição de padrões:

Montar uma câmara para tirar algumas fotografias

Começam a notar-se algumas diferenças entre os dois tipos de peixe:

Comprimento

Largura

Brilho

Posição da boca

Número e forma das barbatanas

*(Todas são **possíveis características**)*

Perca ou Salmão?

Pré-processamento:

Remover artefactos e ruído;

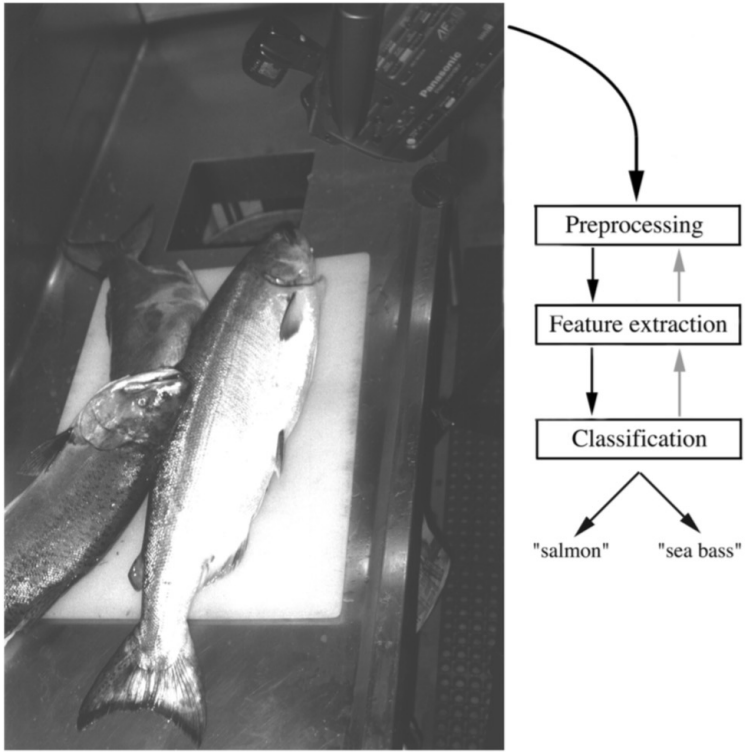
Segmentação;

Feature Extraction:

As características de cada peixe poderão então ser extraídas (comprimento, largura, brilho, número de barbatanas)

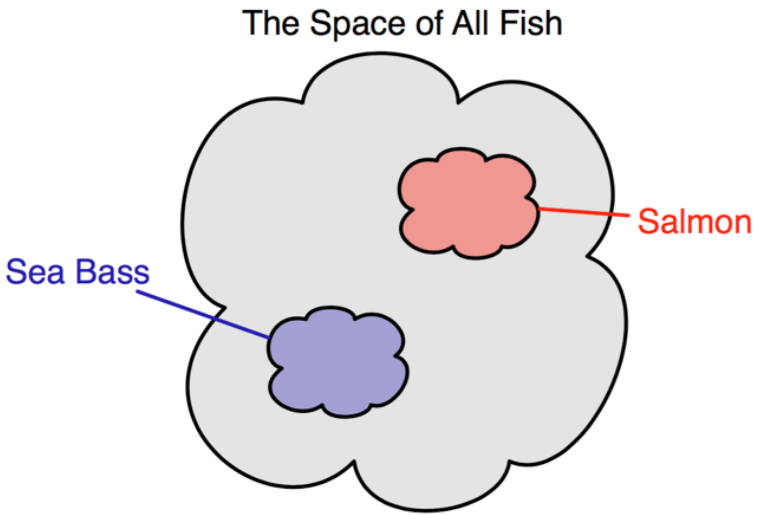
Classificação:

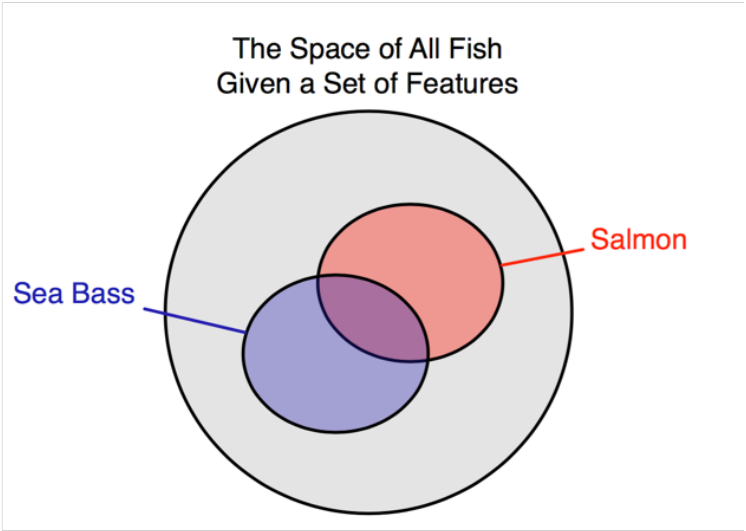
As características são passadas a um classificador, que as avalia e toma a decisão final acerca da espécie de cada peixe.



Perca ou Salmão?

Que características?





Perca ou Salmão?

Comprimento ou brilho?

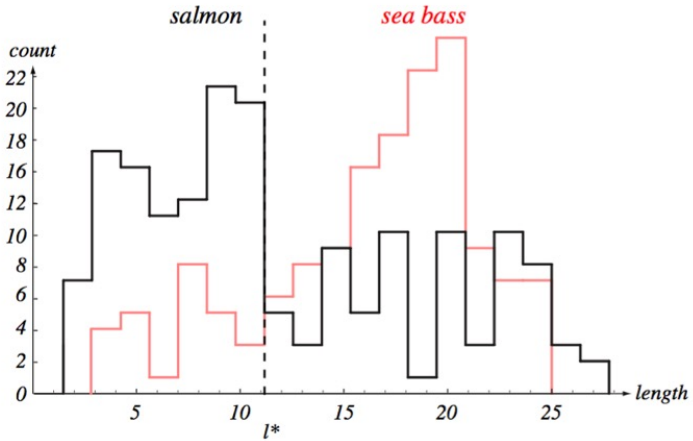


FIGURE 1.2. Histograms for the length feature for the two categories. No single threshold value of the length will serve to unambiguously discriminate between the two categories; using length alone, we will have some errors. The value marked *l** will lead to the smallest number of errors, on average. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

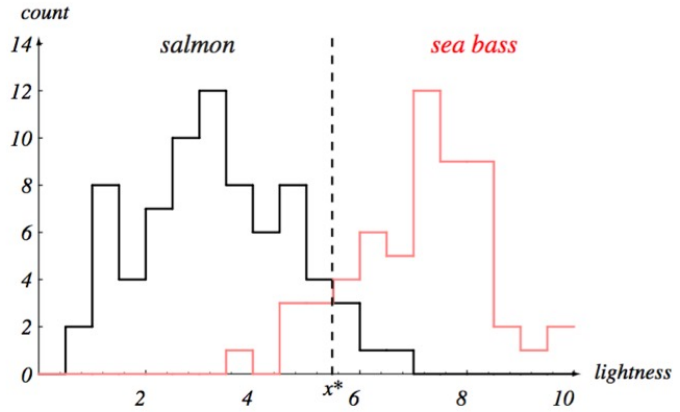
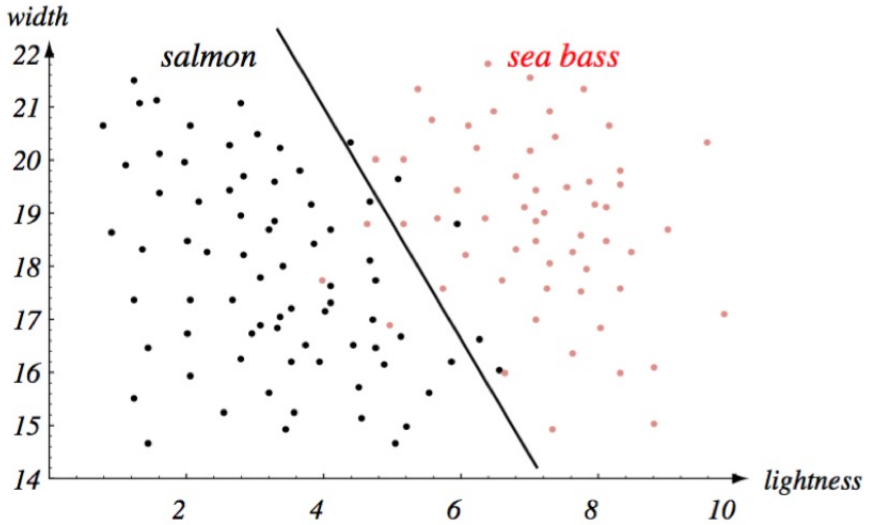


FIGURE 1.3. Histograms for the lightness feature for the two categories. No single threshold value *x** (decision boundary) will serve to unambiguously discriminate between the two categories; using lightness alone, we will have some errors. The value *x** marked will lead to the smallest number of errors, on average. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

Perca ou Salmão?

Manter a característica *brilho* e adicionar outra, a *largura*:

- Os padrões (cada peixe) passam a ser caracterizados pelo seu brilho e largura;
- Cada peixe é um ponto, ou um vector **x**, num espaço bi-dimensional (2D)



Fim
Good job!